





EXAMEN U2

ANALISIS DE DATOS

**MARQUEZ BAILON ELIAS
MANUEL**

GRUPO: 9ªA
Fecha: 04/Julio/2026



Captura del repositorio con la estructura solicitada.

The screenshot shows a GitHub repository page for 'unidad2_etl_biblioteca'. The repository is public and has 0 stars, 0 forks, and 0 watchers. The main branch is 'main'. The repository description is 'Proyecto ETL de préstamos de biblioteca utilizando Python, Pandas y MySQL'. The repository contains the following files and folders:

File/Folder	Commit Message	Commit Time
data	chore: estructura inicial del proyecto ETL	18 hours ago
evidencias	chore: estructura inicial del proyecto ETL	18 hours ago
scripts	feat: implementar lectura y limpieza del dataset	12 hours ago
sql	chore: estructura inicial del proyecto ETL	18 hours ago
.gitignore	feat: implementar lectura y limpieza del dataset	12 hours ago
README.md	chore: estructura inicial del proyecto ETL	18 hours ago
requirements.txt	feat: implementar lectura y limpieza del dataset	12 hours ago

The repository also has a README file and a requirements.txt file. The repository is currently empty of code.

Captura de ejecución del script.

```
(.venv) PS C:\Users\corey\OneDrive\Desktop\unidad2_etl_biblioteca> python scripts\etl_biblioteca.py
=====
FASE 4 - EXTRACCIÓN Y LIMPIEZA
=====

--- DATOS CRUDOS ---
Dimensiones: (100, 10)

Columnas: ['id_prestamo', 'fecha_prestamo', 'alumno', 'carrera', 'libro', 'categoria', 'dias_prestamo', 'multa_diaria', 'sede', 'total_multa']

Tipos de datos:
id_prestamo      int64
fecha_prestamo   str
alumno           str
carrera          str
libro            str
categoria        str
dias_prestamo    int64
multa_diaria     int64
sede             str
total_multa      int64
dtype: object
```

```
Primeras 3 filas:
   id_prestamo fecha_prestamo  alumno carrera      libro      categoria  dias_prestamo  multa_diaria      sede  total_multa
0         5001    2026-06-01  Ana Lopez  IDGS    Python Basico  Programacion         3          0  Biblioteca Central         0
1         5002    2026-06-02  Luis Perez  IRD    Bases de Datos I  Bases de datos         5          5      Sala Norte         25
2         5003    2026-06-03  Sofia Ruiz  IGE    Minería de Datos    Analitica         7         10      Sala Sur         70

Valores nulos:
id_prestamo      0
fecha_prestamo   0
alumno           0
carrera          0
libro            0
categoria        0
dias_prestamo    0
multa_diaria     0
sede             0
total_multa      0
dtype: int64
```

```
--- DATOS LIMPIOS ---
Dimensiones: (100, 10)

Columnas: ['id_prestamo', 'fecha_prestamo', 'alumno', 'carrera', 'libro', 'categoria', 'dias_prestamo', 'multa_diaria', 'sede', 'total_multa']

Tipos de datos:
id_prestamo      int64
fecha_prestamo   datetime64[us]
alumno           str
carrera          str
libro            str
categoria        str
dias_prestamo    int64
multa_diaria     int64
sede             str
total_multa      int64
dtype: object
```

Primeras 3 filas:

	id_prestamo	fecha_prestamo	alumno	carrera	libro	categoria	dias_prestamo	multa_diaria	sede	total_multa
0	5001	2026-06-01	Ana Lopez	IDGS	Python Basico	Programacion	3	0	Biblioteca Central	0
1	5002	2026-06-02	Luis Perez	IRD	Bases de Datos I	Bases de datos	5	5	Sala Norte	25
2	5003	2026-06-03	Sofia Ruiz	IGE	Mineria de Datos	Analitica	7	10	Sala Sur	70

Valores nulos:

id_prestamo 0
fecha_prestamo 0
alumno 0
carrera 0
libro 0
categoria 0
dias_prestamo 0
multa_diaria 0
sede 0
total_multa 0
dtype: int64

FASE 5 - CONEXION A MySQL Y CREACION DEL DW

[OK] Conexion exitosa a MySQL
[OK] Tablas creadas / verificadas correctamente
[OK] Tablas limpiadas correctamente

Tablas en biblioteca_dw: ['dim_alumno', 'dim_carrera', 'dim_fecha', 'dim_libro', 'dim_sede', 'etl_errores', 'etl_log', 'fact_prestamos']

FASE 6 - VALIDACIONES DEL ETL

Filas leidas: 100
Filas cargadas: 98
Filas rechazadas: 2

--- ERRORES DETECTADOS (2) ---

Fila CSV 100: total_multa incorrecto (id: 5099)
Fila CSV 101: id_prestamo duplicado (id: 5002)

FASE 7 - CARGA DEL DATA WAREHOUSE

[OK] Dimensiones cargadas
[OK] 98 registros cargados en fact_prestamos
[OK] 2 errores registrados en etl_errores
[OK] Registro guardado en etl_log (Estado: FINALIZADO_CON_ERRORES)
[OK] Reporte generado: evidencias\reporte_ejecucion.txt


ETL FINALIZADO

Resumen:

Archivo: prestamos_biblioteca_100.csv
Filas leidas: 100
Filas cargadas: 98
Filas rechazadas: 2
Estado: FINALIZADO_CON_ERRORES

(.venv) PS C:\Users\corey\OneDrive\Desktop\unidad2_etl_biblioteca>

Captura de las tablas creadas en MySQL.



The screenshot shows a MySQL IDE interface. The top toolbar includes icons for file operations, execution, and a dropdown menu set to "Limit to 50000 rows". The SQL editor contains two commands: `use biblioteca_dw;` and `show tables;`. Below the editor, the "Result Grid" tab is active, displaying the output of the `show tables;` command. The grid lists the tables in the `biblioteca_dw` database: `dim_alumno`, `dim_carrera`, `dim_fecha`, `dim_libro`, `dim_sede`, and `etl_errores`. A tab labeled "Result 8" is visible at the bottom.


```
1 • use biblioteca_dw;
2
3 • show tables;
4
5
6
7
8
9
10
11
12
```

Result Grid | Filter Rows: | Export: | Wrap Cell Content: ☐

	Tables_in_biblioteca_dw
▶	dim_alumno
	dim_carrera
	dim_fecha
	dim_libro
	dim_sede
	etl_errores

Result 8 x

Captura de `fact\_prestamos` con datos.



The screenshot shows a SQL IDE interface with a query editor and a results grid. The query editor contains the following SQL commands:

```
1 • use biblioteca_dw;  
2  
3 • show tables;  
4  
5 • select * from fact_prestamos;
```

The results grid displays the data from the `fact\_prestamos` table. The columns are: `id\_prestamo`, `id\_fecha`, `id\_alumno`, `id\_carrera`, `id\_libro`, `id\_sede`, `dias\_prestamo`, `multa\_diaria`, and `total\_multa`.

	id_prestamo	id_fecha	id_alumno	id_carrera	id_libro	id_sede	dias_prestamo	multa_diaria	total_multa
▶	5001	20260601	41	11	21	9	3	0.00	0.00
	5002	20260602	42	12	22	10	5	5.00	25.00
	5003	20260603	43	13	23	11	7	10.00	70.00
	5004	20260604	44	14	24	12	2	15.00	30.00
	5005	20260605	45	15	25	9	4	0.00	0.00
	5006	20260606	46	11	26	10	6	5.00	30.00
	5007	20260607	47	12	27	11	8	10.00	80.00
	5008	20260608	48	13	28	12	1	15.00	15.00
	5009	20260609	49	14	29	9	9	0.00	0.00
	5010	20260610	50	15	30	10	10	5.00	50.00
	5011	20260611	51	11	21	11	3	10.00	30.00
	5012	20260612	52	12	22	12	5	15.00	75.00
	5013	20260613	53	13	23	9	7	0.00	0.00
	5014	20260614	54	14	24	10	2	5.00	10.00
	5015	20260615	55	15	25	11	4	10.00	40.00
	5016	20260616	56	11	26	12	6	15.00	90.00
	5017	20260617	57	12	27	9	8	0.00	0.00
	5018	20260618	58	13	28	10	1	5.00	5.00
	5019	20260619	59	14	29	11	9	10.00	90.00
	5020	20260620	60	15	30	12	10	15.00	150.00
	5021	20260621	41	11	21	9	3	0.00	0.00
	5022	20260622	42	12	22	10	5	5.00	25.00

Captura de `etl\_errores` con los 2 errores.

[illegible]

Captura de `etl\_log`.

[illegible]

Captura o evidencia de las consultas SQL.

```
7      -- 1. Cuantos registros hay en fact_prestamos
8  •    SELECT COUNT(*) AS total_prestamos FROM fact_prestamos;
```

Result Grid	Filter Rows:	Export:	Wrap Cell Content:
total_prestamos			
▶ 98			

```
10     -- 2. Cuantos registros hay en etl_errores
11  •    SELECT COUNT(*) AS total_errores FROM etl_errores;
12
```

Result Grid	Filter Rows:	Export:	Wrap Cell Content:
total_errores			
▶ 2			

```
13     -- 3. Que errores fueron registrados
14  •    SELECT id_error, id_registro, descripcion_error, fila_csv, fecha_error
15  FROM etl_errores;
```

Result Grid

Filter Rows:

Edit:

Export/Import:

Wrap Cell Content:

	id_error	id_registro	descripcion_error	fila_csv	fecha_error
▶	3	5099	total_multa incorrecto	100	2026-07-05 09:14:12
	4	5002	id_prestamo duplicado	101	2026-07-05 09:14:12
*	NULL	NULL	NULL	NULL	NULL

```
17     -- 4. Cual fue el ultimo estado registrado en etl_log
18  •    SELECT id_log, fecha_ejecucion, estado, filas_leidas, filas_cargadas, filas_rechazadas
19  FROM etl_log
20  ORDER BY id_log DESC
21  LIMIT 1;
22
```

Result Grid

Filter Rows:

Edit:

Export/Import:

Wrap Cell Content:

Fetch rows:

	id_log	fecha_ejecucion	estado	filas_leidas	filas_cargadas	filas_rechazadas
▶	2	2026-07-05 09:14:12	FINALIZADO_CON_ERRORES	100	98	2
*	NULL	NULL	NULL	NULL	NULL	NULL

```

23      -- 5. Total de multas por carrera
24      • SELECT c.carrera, SUM(f.total_multa) AS total_multas
25      FROM fact_prestamos f
26      JOIN dim_carrera c ON f.id_carrera = c.id_carrera
27      GROUP BY c.carrera
28      ORDER BY total_multas DESC;
29

```

Result Grid			Filter Rows:	Export:	Wrap Cell Content:
	carrera	total_multas			
▶	DNAM	1050.00			
	IRD	900.00			
	IDGS	750.00			
	ITI	560.00			
	IGE	450.00			

```

30      -- 6. Total de multas por categoria de libro
31      • SELECT l.categoria, SUM(f.total_multa) AS total_multas
32      FROM fact_prestamos f
33      JOIN dim_libro l ON f.id_libro = l.id_libro
34      GROUP BY l.categoria
35      ORDER BY total_multas DESC;
36

```

Result Grid			Filter Rows:	Export:	Wrap Cell Content:
	categoria	total_multas			
▶	Inteligencia artificial	850.00			
	Analitica	710.00			
	Bases de datos	600.00			
	Matematicas	600.00			
	Sistemas	400.00			
	Software	200.00			
	Redes	200.00			
	Programacion	150.00			

```

37      -- 7. Promedio de dias de prestamo por sede
38 •    SELECT s.sede, AVG(f.dias_prestamo) AS promedio_dias
39      FROM fact_prestamos f
40      JOIN dim_sede s ON f.id_sede = s.id_sede
41      GROUP BY s.sede
42      ORDER BY promedio_dias DESC;
43

```

Result Grid   Filter Rows: | Export:  | Wrap Cell Content: 

	sede	promedio_dias
▶	Biblioteca Central	6.2000
	Sala Sur	6.0833
	Sala Norte	4.8000
	Laboratorio Digital	4.5833

```

44      -- 8. Los 5 libros con mayor total de multa
45 •    SELECT l.libro, l.categoria, SUM(f.total_multa) AS total_multas
46      FROM fact_prestamos f
47      JOIN dim_libro l ON f.id_libro = l.id_libro
48      GROUP BY l.libro, l.categoria
49      ORDER BY total_multas DESC
50      LIMIT 5;
51

```

Result Grid   Filter Rows: | Export:  | Wrap Cell Content:  | Fetch rows:

	libro	categoria	total_multas
▶	Fundamentos de IA	Inteligencia artificial	850.00
	Estadística Aplicada	Matematicas	600.00
	Bases de Datos I	Bases de datos	500.00
	Linux para Todos	Sistemas	400.00
	Análisis de Datos	Analítica	360.00

```

52  -- 9. Prestamos detallados con fecha, alumno, carrera, libro, categoria, sede y total de multa
53  •  SELECT
54      fe.fecha,
55      a.alumno,
56      c.carrera,
57      l.libro,
58      l.categoria,
59      s.sede,
60      f.total_multa
61  FROM fact_prestamos f
62  JOIN dim_fecha fe ON f.id_fecha = fe.id_fecha
63  JOIN dim_alumno a ON f.id_alumno = a.id_alumno
64  JOIN dim_carrera c ON f.id_carrera = c.id_carrera
65  JOIN dim_libro l ON f.id_libro = l.id_libro
66  JOIN dim_sede s ON f.id_sede = s.id_sede
67  ORDER BY fe.fecha, a.alumno;

```

Result Grid Filter Rows: Export: Wrap Cell Content:							
	fecha	alumno	carrera	libro	categoria	sede	total_multa
▶	2026-06-01	Ana Lopez	IDGS	Python Basico	Programacion	Biblioteca Central	0.00
	2026-06-01	Daniel Torres	ITI	Analisis de Datos	Analitica	Biblioteca Central	0.00
	2026-06-01	Laura Diaz	DNAM	Ingenieria de Software	Software	Biblioteca Central	0.00
	2026-06-01	Valeria Cruz	IRD	Linux para Todos	Sistemas	Biblioteca Central	0.00
	2026-06-02	Carlos Luna	IDGS	Estadistica Aplicada	Matematicas	Sala Norte	30.00
	2026-06-02	Hector Medina	IGE	SQL Practico	Bases de datos	Sala Norte	5.00
	2026-06-02	Luis Perez	IRD	Bases de Datos I	Bases de datos	Sala Norte	25.00
	2026-06-02	Paola Reyes	DNAM	Fundamentos de IA	Inteligencia artificial	Sala Norte	50.00

```

69  -- 10. Conteo de prestamos por sede
70  •  SELECT s.sede, COUNT(*) AS total_prestamos
71  FROM fact_prestamos f
72  JOIN dim_sede s ON f.id_sede = s.id_sede
73  GROUP BY s.sede
74  ORDER BY total_prestamos DESC;

```

Result Grid Filter Rows: Export: Wrap Cell Content:		
	sede	total_prestamos
▶	Biblioteca Central	25
	Sala Norte	25
	Laboratorio Digital	24
	Sala Sur	24

Breve explicación del flujo ETL.

El proyecto se dividió en 8 fases para mantener un desarrollo ordenado. Cada fase representa una etapa del ciclo ETL y se completó antes de pasar a la siguiente, realizando commits en Git para mantener un historial claro.

Estructura del repositorio

Se creó la carpeta `unidad2_etl_biblioteca` con la estructura solicitada: `data/` para el dataset, `scripts/` para el código Python, `sql/` para las consultas de verificación, y `evidencias/` para los reportes y documentos de entrega.

Fase 1 - Preparación del proyecto: Se inicializó el repositorio Git y se creó la estructura de carpetas, el README inicial, `.gitignore`, `requirements.txt` y se agregó el dataset `prestamos_biblioteca_100.csv`.

Fase 2 - Preparación del entorno: Se creó y activó el entorno virtual `.venv`, se actualizó pip y se instalaron las dependencias: `pandas`, `sqlalchemy`, `pymysql` y `openpyxl`.

Fase 3 - Diseño de la arquitectura: Se planificó el flujo del ETL definiendo las funciones del script (extraer, limpiar, validar, conectar, crear tablas, cargar dimensiones, cargar hechos, registrar errores, registrar log y generar reporte) y se creó el esqueleto de `etl_biblioteca.py`.

Fase 4 - Extracción y limpieza: Se implementó la lectura del CSV con `pandas`, estandarización de nombres de columnas a minúsculas, eliminación de espacios en texto, conversión de `fecha_prestamo` a `datetime` y de columnas numéricas a tipos numéricos.

Fase 5 - Conexión a MySQL y creación del Data Warehouse: Se conectó a MySQL local (puerto 3306, usuario root) creando la base `biblioteca_dw` y 8 tablas: `dim_alumno`, `dim_carrera`, `dim_libro`, `dim_sede`, `dim_fecha`, `fact_prestamos`, `etl_errores` y `etl_log`, usando SQLAlchemy con PyMySQL.

Fase 6 - Validaciones: Se aplicaron dos reglas de negocio: a) validar que `total_multa = dias_prestamo * multa_diaria`, b) detectar `id_prestamo` duplicados (la primera ocurrencia es válida, la segunda se rechaza). De 100 registros, 98 resultaron válidos y 2 fueron rechazados.

Fase 7 - Carga del Data Warehouse: Se insertaron los valores únicos en las 5 dimensiones, se mapearon los IDs y se cargaron 98 registros en fact_prestamos. Los 2 errores se almacenaron en etl_errores y el resumen de ejecución en etl_log. Se generó automáticamente evidencias/reporte_ejecucion.txt.

Fase 8 - Documentación final: Se completaron 10 consultas SQL de verificación en consultas_verificacion.sql, se actualizó el README con instrucciones de instalación y ejecución, y se preparó el PDF de evidencias con capturas del proceso.